

03-通过你的CPU主频，我们来谈谈“性能”究竟是什么？


“性能”这个词，不管是在日常生活还是写程序的时候，都经常被提到。比方说，买新电脑的时候，我们会说“原来的电脑性能跟不上了”；写程序的时候，我们会说，“这个程序性能需要优化一下”。那么，你有没有想过，我们常常挂在嘴边的“性能”到底指的是什么呢？我们能不能给性能下一个明确的定义，然后来进行准确的比较呢？

在计算机组成原理乃至体系结构中，“性能”都是最重要的一个主题。我在前面说过，学习和研究计算机组成原理，就是在理解计算机是怎么运作的，以及为什么要这么运作。“为什么”所要解决的事情，很多时候就是提升“性能”。

什么是性能？时间的倒数


计算机的性能，其实和我们干体力劳动很像，好比是我们要搬东西。对于计算机的性能，我们需要有个标准来衡量。这个标准中主要有两个指标。

第一个是**响应时间**（Response time）或者叫执行时间（Execution time）。想要提升响应时间这个性能指标，你可以理解为让计算机“跑得更快”。



图中是我们实际系统里性能监测工具NewRelic中的响应时间，代表了每个外部的Web请求的执行时间

第二个是**吞吐率**（Throughput）或者带宽（Bandwidth），想要提升这个指标，你可以理解为让计算机“搬得更多”。



服务器使用的网络带宽，通常就是一个吞吐率性能指标

所以说，响应时间指的就是，我们执行一个程序，到底需要花多少时间。花的时间越少，自然性能就越好。

而吞吐率是指我们在一定的时间范围内，到底能处理多少事情。这里的“事情”，在计算机里就是处理的数据或者执行的程序指令。

和搬东西来做对比，如果我们的响应时间短，跑得快，我们可以来回多跑几趟多搬几趟。所以说，缩短程序的响应时间，一般来说都会提升吞吐率。

除了缩短响应时间，我们还有别的方法吗？当然有，比如说，我们还可以多找几个人一起来搬，这就类似现代的服务器都是8核、16核的。人多力量大，同时处理数据，在单位时间内就可以处理更多数据，吞吐率自然也就上去了。

提升吞吐率的办法有很多。大部分时候，我们只要多加一些机器，多堆一些硬件就好了。但是响应时间的提升却没有那么容易，因为CPU的性能提升其实在10年前就处于“挤牙膏”的状态了，所以我们得慎重地来分析对待。下面我们具体来看。

我们一般把性能，定义成响应时间的倒数，也就是：

$$\text{性能} = 1/\text{响应时间}$$

这样一来，响应时间越短，性能的数值就越大。同样一个程序，在Intel最新的CPU Coffee Lake上，只需要30s就能运行完成，而在5年前CPU Sandy Bridge上，需要1min才能完成。那么我们自然可以算出来，Coffee Lake的性能是1/30，Sandy Bridge的性能是1/60，两个的性能比为2。于是，我们就可以说，Coffee Lake的性能是Sandy Bridge的2倍。

过去几年流行的手机跑分软件，就是把多个预设好的程序在手机上运行，然后根据运行需要的时间，算出一个分数来给出手机的性能评估。而在业界，各大CPU和服务商组织了一个叫作SPEC (Standard Performance Evaluation Corporation) 的第三方机构，专门用来指定各种“跑分”的规则。

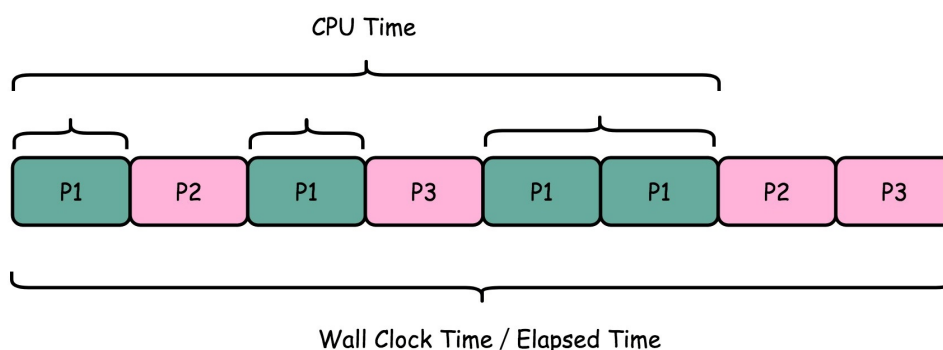
序实际在CPU上到底花了多少时间。

我们简单运行一下time命令。它会返回三个值，第一个是**real time**，也就是我们说的Wall Clock Time，也就是运行程序整个过程中流逝掉的时间；第二个是**user time**，也就是CPU在运行你的程序，在用户态运行指令的时间；第三个是**sys time**，是CPU在运行你的程序，在操作系统内核里运行指令的时间。而**程序实际花费的CPU执行时间（CPU Time），就是user time加上sys time**。

```
$ time seq 1000000 | wc -l
1000000

real    0m0.101s
user    0m0.031s
sys     0m0.016s
```

在我给的这个例子里，你可以看到，实际上程序用了0.101s，但是CPU time只有 $0.031 + 0.016 = 0.047s$ 。运行程序的时间里，只有不到一半是实际花在这个程序上的。



程序实际占用的CPU时间一般比Elapsed Time要少不少

其次，即使我们已经拿到了CPU时间，我们也不一定可以直接“比较”出两个程序的性能差异。即使在同一台计算机上，CPU可能满载运行也可能降频运行，降频运行的时候自然花的时间会多一些。

除了CPU之外，时间这个性能指标还会受到主板、内存这些其他相关硬件的影响。所以，我们需要对“时间”这个我们可以感知的指标进行拆解，把程序的CPU执行时间变成 CPU时钟周期数（CPU Cycles）和时钟周期时间（Clock Cycle）的乘积。

程序的CPU执行时间=CPU时钟周期数×时钟周期时间

我们先来理解一下什么是时钟周期时间。你在买电脑的时候，一定关注过CPU的主频。比如我手头的这台电脑就是Intel Core-i7-7700HQ 2.8GHz，这里的2.8GHz就是电脑的主频（Frequency/Clock Rate）。这个2.8GHz，我们可以先粗略地认为，CPU在1秒时间内，可以执行的简单指令的数量是2.8G条。

如果想要更准确一点描述，这个2.8GHz就代表，我们CPU的一个“钟表”能够识别出来的最小的时间间隔。就像我们挂在墙上的挂钟，都是“滴答滴答”一秒一秒地走，所以通过墙上的挂钟能够识别出来的最小时间单位就是秒。

而在CPU内部，和我们平时戴的电子石英表类似，有一个叫晶体振荡器（Oscillator Crystal）的东西，简称为晶振。我们把晶振当成CPU内部的电子表来使用。晶振带来的每一次“滴答”，就是时钟周期时间。

在我这个2.8GHz的CPU上，这个时钟周期时间，就是1/2.8G。我们的CPU，是按照这个“时钟”提示的时间来进行自己的操作。主频越高，意味着这个表走得越快，我们的CPU也就“被逼”着走得越快。

如果你自己组装过台式机的话，可能听说过“超频”这个概念，这说的其实就相当于把买回来的CPU内部的钟给调快了，于是CPU的计算跟着这个时钟的节奏，也就自然变快了。当然这个快不是没有代价的，CPU跑得越快，散热的压力也就越大。就和人一样，超过生理极限，CPU就会崩溃了。

我们现在回到上面程序CPU执行时间的公式。

程序的CPU执行时间=CPU时钟周期数×时钟周期时间

最简单的提升性能方案，自然缩短时钟周期时间，也就是提升主频。换句话说，就是换一块好一点的CPU。不过，这个是我们这些软件工程师控制不了的事情，所以我们就把目光挪到了乘法的另一个因子——CPU时钟周期数上。如果能够减少程序需要的CPU时钟周期数量，一样能够提升程序性能。

对于CPU时钟周期数，我们可以再做一个分解，把它变成“指令数×**每条指令的平均时钟周期数**（Cycles Per Instruction，简称CPI）”。不同的指令需要的Cycles是不同的，加法和乘法都对对应着一条CPU指令，但是乘法需要的Cycles就比加法要多，自然也就慢。在这样拆分了之后，我们的程序的CPU执行时间就可以变成这样三个部分的乘积。

程序的CPU执行时间=指令数×CPI×Clock Cycle Time

因此，如果我们想要解决性能问题，其实就是要优化这三者。

1. 时钟周期时间，就是计算机主频，这个取决于计算机硬件。我们所熟知的[摩尔定律](#)就一直在不停地提高我们计算机的主频。比如说，我最早使用的80386主频只有33MHz，现在手头的笔记本电脑就有2.8GHz，在主频层面，就提升了将近100倍。
2. 每条指令的平均时钟周期数CPI，就是一条指令到底需要多少CPU Cycle。在后面讲解CPU结构的时候，我们会看到，现代的CPU通过流水线技术（Pipeline），让一条指令需要的CPU Cycle尽可能地少。因此，对于CPI的优化，也是计算机组成和体系结构中的重要一环。
3. 指令数，代表执行我们的程序到底需要多少条指令、用哪些指令。这个很多时候就把挑战交给了编译器。同样的代码，编译成计算机指令时候，就有各种不同的表示方式。

我们可以把自己想象成一个CPU，坐在那里写程序。计算机主频就好像是你的打字速度，打字越快，你自然可以多写一点程序。CPI相当于你在写程序的时候，熟悉各种快捷键，越是打同样的内容，需要敲击键盘的次数就越少。指令数相当于你的程序设计得够合理，同样的程序要写的代码行数就少。如果三者皆能实现，你自然可以很快地写出一个优秀的程序，你的“性能”从外面来看就是好的。

总结延伸

好了，学完这一讲，对“性能”这个名词，你应该有了更清晰的认识。我主要对于“响应时间”这个性能指标进行抽丝剥茧，拆解成了计算机时钟周期、CPI以及指令数这三个独立的指标的乘积，并且为你指明了优化计算机性能三条康庄大道。也就是，提升计算机主频，优化CPU设计使得在单个时钟周期内能够执行更多指令，以及通过编译器来减少需要的指令数。

在后面的几讲里面，我会为你讲解，具体怎么在电路硬件、CPU设计，乃至指令设计层面，提升计算机的性能。

课后思考

每次有新手机发布的时候，总会有一些对于手机的跑分结果的议论。乃至有“作弊”跑分或者“针对跑分优化”的说法。我们能针对“跑分”作弊么？怎么做到呢？“作弊”出来的分数对于手机性能还有参考意义么？

欢迎留言和我分享你的思考和疑惑，你也可以把今天的内容分享给你的朋友，和他一起学习和进步。



深入浅出计算机组成原理

带你掌握计算机体系全貌

徐文浩 bothub 创始人



新版升级：点击「👤请朋友读」，20位好友免费读，邀请订阅更有**现金**奖励。

精选留言：

- changing 2019-04-29 08:59:33

运行的代码是 `time seq 100000 | wc -l`

real 0m0.033s

user 0m0.030s

sys 0m0.005s

为什么user + sys 运行出来会比real time 多呢 [13赞]

作者回复2019-04-29 18:57:12

changing同学你好，一般情况下，如果user+sys比real大，甚至光光user比real大的情况出现，都是因为对应的程序被多个进程或者多个线程并行执行了，也很常见。不过你遇到的这个问题的确有些奇怪，我要研究一下，因为linux下的seq和wc这些命令按照我的理解都是单线程运行的。
能告诉我你使用的硬件和操作系统么？

- 潜默闻雨 2019-04-29 08:23:47

徐老师，程序的cpu执行时间是不是由很多cpu时间片组成，而cpu并不知道自己在执行哪个程序的指令，只是按时间片去按顺序执行指令，不知道这样理解对不对？非科班的转行人士，正在努力补基础☺。。。 [2赞]

- sunbiaozj 2019-04-29 07:43:25

文章思路非常清晰，很棒 [2赞]

- 陈华应 2019-04-29 00:05:02
好准时，打个卡 ~~ [1赞]

- ... 2019-04-30 08:40:40
讲的非常好，思路清晰明了

- 爷爷刘大 2019-04-30 08:27:31
changing 同学的问题在stackoverflow 上的解释是这样的：
The rule of thumb is:

real < user: The process is CPU bound and takes advantage of parallel execution on multiple cores/CPU's.

real ≈ user: The process is CPU bound and takes no advantage of parallel execution.

real > user: The process is I/O bound. Execution on multiple cores would be of little to no advantage.

<https://unix.stackexchange.com/questions/40694/why-real-time-can-be-lower-than-user-time>

- 爷爷刘大 2019-04-30 08:22:46
changing 同学发现的现象我也重现了：
time seq 10000000 | wc -l
10000000
real 0m2.783s
user 0m2.836s
sys 0m0.063s
我用的是mac os high sierra 10.13.6

- Only now 2019-04-30 08:08:59
猜测，跑分程序载入后，停止操作系统的线程调度或者给最高优先级和响应中断，全力跑跑分。暂时提高时钟频率，停止温度检测和低级中断，这样CPU就全力在跑测试程序了吧。

没做过弊，猜测

- KR® 2019-04-30 03:40:12
又重刷了一遍前四讲，徐老师讲得又清惜又易懂，老师备课花了不少心血吧...
现在等待更新的心情就像追了一部超高分剧等更一样!!辛苦徐老师备课喇^^

- humor 2019-04-30 00:14:50
对于文中的CPU钟表时间间隔和时钟周期还是没有理解很清楚，时间间隔和时钟周期是互为倒数的关系吗？就是CPU主频是一个单位时间，而时钟周期就是这个单位时间被分成主频(2.8G)等份的一份吗？

- 等风来 2019-04-29 23:55:00
老师CPU内部的晶体振荡器， 有哪些作用呢

- xiaowenzi 2019-04-29 22:15:45
打卡

- tuyu 2019-04-29 20:36:00

跑分作弊应该是开了超频

老师，我想问阿里云这些云服务商可以开超频吗，哈哈，这样就能省钱啦

- 趁早 2019-04-29 19:38:34

```
time seq 100000 | wc -l  
100000
```

```
real 0m0.006s  
user 0m0.003s  
sys 0m0.004s
```

我也是类似的问题，操作系统centos7.4，物理环境阿里云ecs

cpu 信息

Intel(R) Xeon(R) Platinum 8163 CPU @ 2.50GHz

- YUANWOW 2019-04-29 18:19:13

手机跑分作弊我是这么理解的

一是检测到跑分软件就放开温度墙和功耗墙的限制 相当于提高主频

二是跑分程序对于机型做了专门优化 相当于优化CPI和减少指令数

作弊出来的分数只对销量有意义

- 曾经瘦过 2019-04-29 16:46:20

打卡 坚持中 希望后面能看到具体的例子 能够学以致用 加深理解

- 静静的拼搏 2019-04-29 15:54:14

觉得可以作弊，主要在cpu频率进行超频和通过编译减少程序执行的指令和执行时间，这样的分数比较片面，有一定的参考价值，但不能作为日常使用的性能参考

作者回复2019-04-29 18:46:07

静静的拼搏你好，的确有这么干的，一监测到是运行跑分程序就超频或者控制即使过热了也不降频来进行运算以获得一个更高的分数

- KR® 2019-04-29 15:03:23

看懂了，在等下一课

- 一步 2019-04-29 14:21:41

有个疑问，现在CPU的时钟周期是不是都是一定的，CPU的频率是根据CPU的处理能力计算出来的。但是现在说的超频是缩短的CPU时钟周期，让在一个更短的周期内处理相同的指令数，但是这个缩短的范围怎么定义的？会不会超过CPU的处理极限，如果每个CPU的时钟周期不一致，那怎么相互比较CPU的性能差异

希望老师解答

- 柠檬C 2019-04-29 13:33:20

猜测作弊优化应该是编译层面，因为已经提前知道了入参，那么可以尽可能的优化指令排序等等？